




Segmentarea semantică pentru secvențe stereo

Student : Neculai Andrei


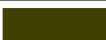









Profesor coordonator : conf. dr. ing. Simona Caraiman

Segmentarea semantică pentru secvențe stereo



Segmentare
semantică



Culoare	Clasa	Culoare	Clasa
	Pixeli neclasificați		Pieton
	Trotuar		Semn de circulație
	Mașină		Gard
	Cer		Clădire
	Stâlp		Drum
	Vegetație	-	-

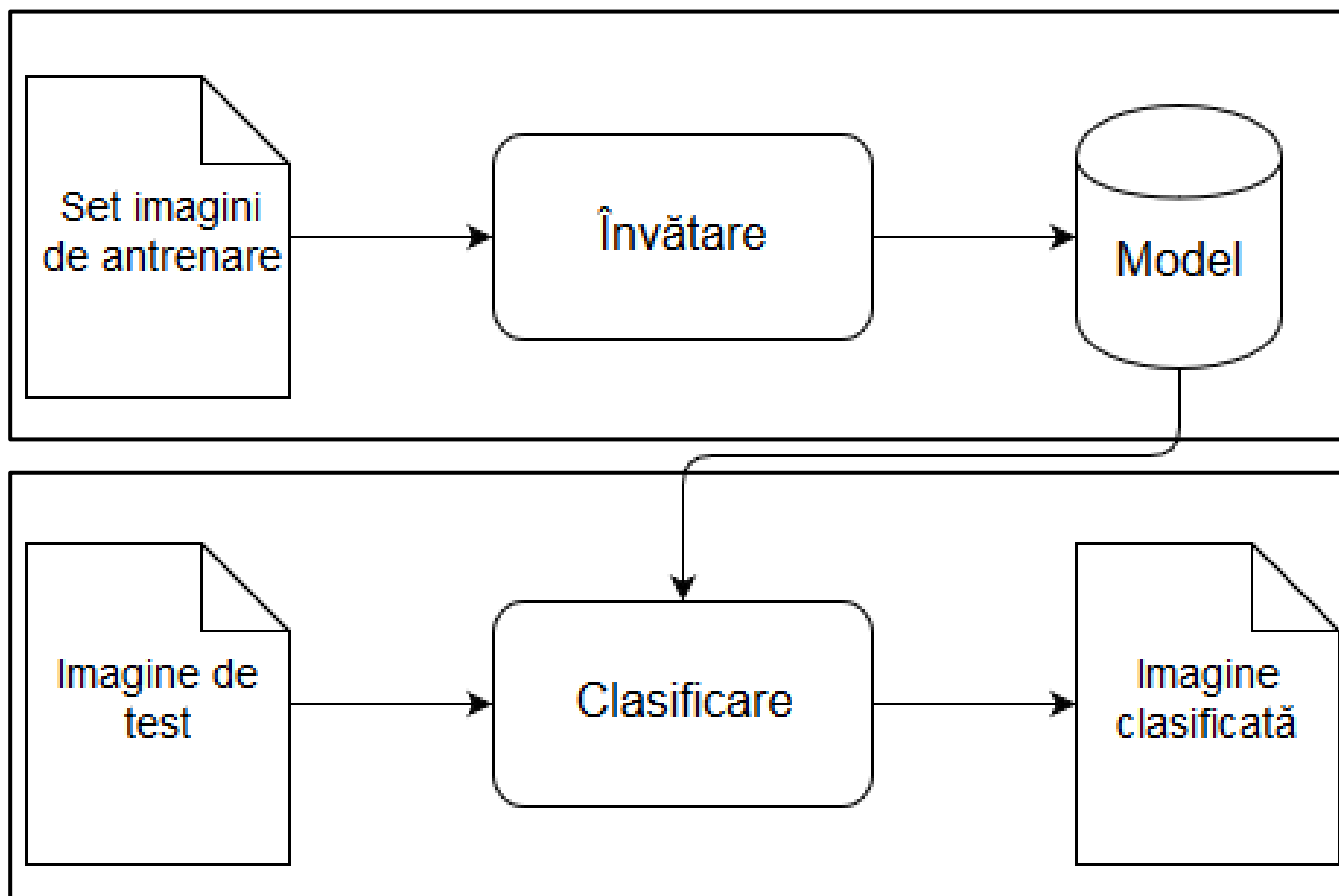


Ce ne-am propus?

- Soluție generică de segmentare semantică
- Bazată pe hărți de adâncime
- Clasificare real-time

Arhitectura aplicației

- Două componente





Arhitectura aplicației


- Cinci module
 - Modulul de preprocesare
 - Modulul de fuziune temporală
 - Modulul de extregere a trăsăturilor
 - Modulul de antrenare/clasificare
 - Modulul de postprocesare




Modulul de preprocesare

- Segmentare în superpixeli (2D)
- Calculare nor de puncte (3D)

Segmentarea în superpixeli



Generare nor de puncte






Modulul de fuziune temporală

- Utilizăm componenta temporală a intrării
- Construim un nor de puncte global prin fuziunea informațiilor cadrului curent cu cele acumulate până în prezent
- Folosim norul de puncte global pentru corectarea erorilor

Modulul de extragere a trăsăturilor

- Trăsături folosite
 - Normala la suprafață
 - Planaritatea locală
 - Planaritatea vecinilor
 - Distanța față de sol
 - Distanța față de planul YOZ
 - Culoarea

Vizualizare trăsături



Distanța față de sol



Modulul de antrenare/clasificare


- Folosim un clasificator Random Forest
- Antrenare
 - Antrenăm o padure de 80 de arbori
- Clasificare
 - Pentru fiecare superpixel rezultă un vector de probabilități de încadrare în fiecare clasă

Modulul de postprocesare

- Algoritm de optimizare Graph Cut
- Minimizarea energiei imaginii calculată ca suma a doi termeni
 - Termen local – favorizează clasa rezultată în urma clasificării
 - Termen de netezire – favorizează clasele superpixelilor vecini

Rezultate experimentale


- 2 seturi de date
 - KITTI – sistem de camere montat pe o masină
 - Set virtual – perspectiva unui pieton



Set de date KITTI




Set de date KITTI



Fără postprocesare – Acuratețe 57%

Set de date KITTI




Cu postprocesare – Acuratețe 74%(+17%)

Set de date virtual




Set de date virtual



Fără postprocesare
Acuratețe 82%



Set de date virtual



Cu postprocesare
Acuratețe 94%(+12%)





Concluzii



Ce ne-am propus?

- Soluție generică de segmentare semantică
- Bazată pe hărți de adâncime
- Clasificare real-time

Ce ne-am propus?

- Soluție generică de segmentare semantică
 - Bazată pe hărți de adâncime
 - Clasificare real-time
- Suficient de generică?

Soluție testată pentru domeniile:

- Conducerea autonomă
- Tehnologii asistive pentru persoane nevăzătoare

Ce ne-am propus?

- Soluție generică de segmentare semantică
- Bazată pe hărți de adâncime
- Clasificare real-time



Suficient de corectă?

Acuratețe medie:

- Set real – 76%
- Set virtual – 93%

Ce ne-am propus?

- Soluție generică de segmentare semantică
- Bazată pe hărți de adâncime
- Clasificare **real-time**

Suficient de rapidă?

Rata de clasificare – ~3 cadre pe secundă



Direcții de dezvoltare

- Îmbunătățirea modului de fuziune temporală
- Incorporarea fuziunii temporale în postprocesare
- Analiza trăsăturilor pentru determinarea gradului de discriminare pentru diverse clase și adăugarea de noi trăsături specifice
- Paralelizarea execuției unor module folosind placă grafică



Vă mulțumesc!